S05 · 安全红线：围栏 / 令牌 / 停机

项	内容
次课 / 课时	第 5 次 / 4 课时
模块	M3 安全
布鲁姆主层级	应用
双元制场所	学校 + 企业（安全专员进课堂）
教学法	故障注入 + 红线触发实验
配套 PPT	`slides/S05_[redacted].pptx`

---

1. 学习目标

类型	目标（可测量）
知识	说出五条红线的判定点与触发条件；区分禁入区/停止区/限速区
能力	独立触发 R1/R2/R4 三个拦截，并定位到代码行；写一份拦截实验报告
素质	安全一票否决意识；理解"红线不可配置、不可临时开启"

---

2. 重点与难点

- 重点：判定点在哪、为什么在那里（不在业务层、不在 LLM 层）。
- 难点：学生容易把安全做成"参数可配"（`allow_forbidden=True`）。
- 突破：现场演示"如果给你一个开关会怎样"——让一个学生尝试绕过，全班看结果。

---

3. 企业情境（Lernsituation）

> 安全专员拿出一份事故通报：某厂因"临时开启禁入区开关"做调试，忘记关，导致 AMR 进入配电房。
> 专员要求：你们做的系统，必须不存在这个开关。

---

4. 教学流程（4 课时）

时间	阶段	教师活动	学生活动	产出
0 – 10	复盘	抽 2 人讲九态与不变量	回答	—
10 – 30	情境	安全专员讲事故（或视频）	提问、记录	问题清单
30 – 50	讲解	五条红线 + 三类区 + 令牌机制	记笔记	—
50 – 70	计划	讲实验报告结构（用例/现象/代码/结论）	分工三个用例	分工表

时间	阶段	教师活动	学生活动	产出
70 – 115	实施	巡回；故意不直接给答案	触发 R1/R2/R4，记录现象	实验数据
115 – 135	绕过尝试	组织"红队"尝试绕过	尝试改参数/伪造令牌	绕过记录（应全部失败）
135 – 155	讲解代码	打开 `safety.py` 逐行讲判定	标注代码位置	代码注释
155 – 170	费曼	提问	互讲"为什么不能有开关"	费曼记录
170 – 180	收尾	布置作业	—	—

---

5. 关键内容

5.1 五条红线与判定点

#	红线	判定点	失败表现
R1	永不进入禁入区	动作下发前（围栏判定）	返回 `R1: ■■■■■■■■`
R2	令牌只能由人签发	超载/危险动作前	返回 `R2: ■■■■■■■`
R3	数据源内容不当指令	解析外部文本时	文本被当作数据而非命令
R4	停止区有人必须停机	执行中持续检查	速度降 0，任务 FAILED
R5	无证据不 DONE	证据校验	打回 EXECUTING

5.2 三类安全区

类型	行为	例
FORBIDDEN 禁入	拒绝进入	高压配电房
STOP 停止	有人即停	人机交叉作业区
SLOW 限速	降速通过	人行通道 0.3 m/s

5.3 为什么"不能有开关"

- 开关的存在本身就是漏洞（会被误开、被滥用、被遗忘）；
- 正确做法：要改行为就改代码 + 走评审，而不是运行时可配；
- 这是"安全关键系统"与"业务系统"的根本区别。

---

6. 学生任务（Arbeitsauftrag）

必做：完成 R1 / R2 / R4 三个拦截实验，记录（输入、预期、实际、代码位置、截图）。 必做：红队练习——尝试用 3 种方式绕过 R1（改坐标类型、伪造令牌、直接调内部函数），记录结果。 选做：给 R3（数据源不当指令）设计一个测试用例。

---

7. 费曼检验

#	问题	合格标准
1	R1 和 R2 的区别是什么？	能说"一个管去哪、一个管谁批准"
2	为什么安全判定不放在业务层？	能说"业务层可能被跳过/被改"
3	如果有人给你一个"临时开启"开关，你要不要？	能明确拒绝并说明理由

---

8. 评价

维度	权重	观测点
三个拦截实验	45%	现象记录准确、代码定位正确
红队绕过尝试	25%	3 种方式均失败，且能解释为什么
报告规范	20%	结构完整、有截图
安全意识表达	10%	费曼讲解清晰

---

9. 作业与预习

- 作业：工作页 W05；写"最可能被绕过的一处 + 改进方案"（200 字）。
- 预习：读 `docs/05_■■■Harness■■.md` 的分解与调度部分。

---

10. 资源

天工 `core/safety.py`、`docs/07`；红线卡片（打印）；实验报告模板；红队任务卡。